

Diagnóstico — Consumo OpenAI (01 a 23/09/2026)

Data: 23/09/2026 · **Fonte:** relatórios de uso da OpenAI (planilhas de *completions*, *cost*, *embeddings*, *images*) cruzados com o banco de **produção** (`cuca` , `svzkrkfpzpiquesloukgb`), o código do repositório, as versões publicadas das Edge Functions e os logs de execução.


Escopo: refeito do zero. Nenhum levantamento anterior foi usado como fonte.

Documento irmão: [PROGNOSTICO-consumo-openai-2026-09-23.md](#). Ele traz as projeções e o plano de redução.

1. Resumo executivo

Pergunta	Resposta curta
Quanto foi gasto?	US\$ 37,89 entre 01 e 23/09 (fatura). O recálculo pelos tokens dá US\$ 37,75 e bate.
Quando subiu?	Média de US\$ 0,71/dia entre 01 e 13/09 e de US\$ 2,87/dia entre 14 e 23/09, 4× mais. Picos: 17/09 (US\$ 7,97), 21/09 (US\$ 5,96), 22/09 (US\$ 4,63).
O que custa?	gpt-4o = 98,2% do gasto (US\$ 37,07). gpt-4o-mini = 1,8% (US\$ 0,68). Embeddings custaram praticamente zero: 114 mil tokens, cerca de US\$ 0,002. Não houve uso de imagem.
Quem chama o gpt-4o?	Principalmente o agente Institucional (motor-agente) . O modelo ajustado explica 99,8% da variação diária do gpt-4o com três variáveis: turnos do Institucional com contexto padrão, turnos com programação completa e processamento de currículo.
Por que subiu?	Por volume de conversas no Institucional , não por aumento do custo de cada chamada. Cada resposta leva de 9 a 21 mil tokens de contexto fixo para o gpt-4o. Houve 3 ondas de volume: o disparo do Simulado Academia Enem (17/09) e duas ondas orgânicas de novos contatos (21 e 22/09).
Mudou algum código ou prompt que aumentou o custo por chamada entre 14/09 e 22/09?	Nenhuma mudança de código elevou o custo por chamada. O motor-agente não recebeu versão nova desde 12/09, e nenhum prompt de agente (<code>prompts_agentes</code>) foi alterado no período (o do Institucional é de 08/09). As mudanças de conteúdo no período foram: (1) edição do documento "Serviços da Rede" em 17/09, que entra em todo turno; o efeito estimado é de no máximo cerca de 200 tokens por turno , porque o tamanho anterior não ficou registrado; (2) FAQ e eventos do simulado (17/09), que só entram quando a busca os traz; (3) mudanças no worker (botão Quick Reply e porteiro da Academia Enem), que alteraram o caminho das mensagens , não o prompt (ver seção 6.1). O salto estrutural de peso por chamada foi anterior : a troca do "Serviços da Rede" da V1 (8,5 mil caracteres) para a V2 (15,8 mil) em 02/09 .
E a programação manual no portal?	Hoje não gera consumo. Outubro está em rascunho (451 atividades nas 5 unidades), a criação manual não chama OpenAI e nada foi indexado ainda. O impacto chega na publicação , pelo tamanho do texto que passa a ir para o gpt-4o (detalhes na seção 7).

Pergunta	Resposta curta
Desperdício identificável?	Sim, em 4 pontos: (1) 186 cliques no botão "Sim, eu vou!" do simulado foram respondidos pelo gpt-4o em vez de resposta pronta; (2) o cache da OpenAI aproveita em média só cerca de 0,8 mil tokens por chamada (maior média diária: 1,9 mil), quando poderia aproveitar cerca de 7,8 mil; (3) o documento "Serviços da Rede" entra inteiro em todo turno; (4) cada trecho da programação repete um cabeçalho de 2 linhas , cerca de 20% do texto.
Há telemetria de consumo?	Não. As tabelas <code>ai_usage_logs</code> (0 linhas) e <code>metricas_openai</code> (4 linhas antigas) não são alimentadas, embora a tela "Consumo" do módulo Developer diga que o registro é automático.



2. As planilhas da OpenAI

2.1 Totais do período (01–23/09, dias em UTC)

Modelo	Chamadas	Tokens de entrada	Em cache	Tokens de saída	Custo recalculado
gpt-4o-2024-08-06	2.102	14.134.100	1.747.968 (12%)	392.117	US\$ 37,07
gpt-4o-mini-2024-07-18	6.013	2.820.762	20.352	429.453	US\$ 0,68
text-embedding-3-small	1.926	114.014	—	—	≈ US\$ 0,002
gpt-6-astra / gpt-image-2.5-flare	4	669	—	939	desprezível


Modelo	Chamadas	Tokens de entrada	Em cache	Tokens de saída	Custo recalculado
Fatura (planilha cost)					US\$ 37,89

Preços usados no recálculo, por milhão de tokens: gpt-4o US\$ 2,50 de entrada, US\$ 1,25 em cache e US\$ 10,00 de saída; gpt-4o-mini US\$ 0,15, US\$ 0,075 e US\$ 0,60. O recálculo bate com a fatura dia a dia. A diferença de US\$ 0,14 vem de embeddings, transcrição de áudio (Whisper) e do outro projeto.


Observações das planilhas:

- O custo está quase todo numa única chave e num único projeto (`key_Tj6w...` / `proj_...NY7jWC`), que é a chave usada pelo worker e pelas Edge Functions.
- Uma segunda chave (`key_gFcQ...`) fez 29 chamadas pequenas de gpt-4o-mini, cerca de 230 tokens cada. O perfil bate com a extração de categorias ou com a análise de sentimento. Custo desprezível.
- Um **terceiro projeto** (`proj_...ZaFSeH` , chave `key_ZjA0...`) fez 4 chamadas em 18/09, com os modelos `gpt-6-astra` e `gpt-image-2.5-flare` . Esses modelos **não aparecem no código do Cuca. Pergunta em aberto:** quem usa esse projeto?
- A planilha de imagens (`images_usage`) está vazia no período inteiro. A leitura de currículo por imagem é cobrada dentro dos tokens do gpt-4o, e não como "imagem".

2.2 O que o gráfico mostra



- O gpt-4o sai de dezenas ou centenas de milhares de tokens por dia para **3,0 milhões em 17/09, 2,5 milhões em 21/09 e 1,8 milhão em 22/09**.
- A média de tokens **por chamada** não tem tendência de alta. Ela oscila entre 1 e 11 mil conforme a mistura do dia: currículo pesa cerca de 1 mil tokens e o Institucional de 9 a 21 mil. Os dias dominados pelo Institucional (09, 10, 21 e 22/09) ficam todos no teto de cerca de 10–11 mil. **Conclusão: subiu a quantidade de chamadas pesadas, não o peso de cada uma.**




3. Quem consome — mapa do código

Todos os pontos do sistema que chamam a OpenAI, rastreados no código:

Onde	Modelo	O que faz	Peso por chamada	Peso no período
supabase/functions/motor-agente (Institucional)	gpt-4o	Responde o cidadão sobre programação, serviços e eventos	9 mil tokens (padrão) a 21 mil (programação completa)	≈ 90% do gpt-4o
motor-agente (avaliar seleção de unidade)	gpt-4o-mini	Classifica a unidade escolhida (até 90 tokens de saída)	pequeno	parte do mini
motor-agente / processar-documento / academia-enem-*	text-embedding-3-small	Busca vetorial e indexação	até 200 tokens por busca	≈ US\$ 0
worker/cv_processor.py	gpt-4o (texto e visão)	Lê o currículo da candidatura ou do banco de talentos	≈ 1 mil tokens por evento (estimado pelo resíduo)	≈ 5–10% do gpt-4o (teto)

Onde	Modelo	O que faz	Peso por chamada	Peso no período
<code>worker/talent_bank_matcher.py</code>	gpt-4o	Rankeia candidatos do banco de talentos para uma vaga (lotes)	variável	incluído no item acima (sem contador próprio)
<code>worker/empregabilidade_engine.py</code> , <code>intencao_detector.py</code> , <code>sentiment_processor.py</code> , <code>category_extractor.py</code> , <code>main.py</code>	gpt-4o-mini	Empregabilidade conversacional, intenção, sentimento, categorias	≈ 470 tokens	US\$ 0,68 no total
<code>worker/meta_adapter_inbound.py</code>	whisper-1	Transcreve áudio	—	desprezível
<code>supabase/functions/academia-enem-agente</code>	gpt-4o	Agente próprio da Academia Enem	—	desprezível: 19 mensagens no total em <code>ae_mensagens</code> , 2 chamadas nas últimas 24h
<code>supabase/functions/gerar-resumo-rede</code>	gpt-4o	Gera o resumo da rede	—	não rodou no período (o resumo ativo é de julho)
<code>cuca-portal/.../developer/batch-triage</code>	gpt-4o / mini	Triagem em lote (tela Developer)	—	uso manual, sem sinal nas planilhas

Empregabilidade: apesar de ser o canal com **mais mensagens** (até 950 respostas por dia), ela usa **gpt-4o-mini** com cerca de 470 tokens por chamada. Por isso custou **menos de 2%** do total. O custo **não** está no volume de mensagens em geral, e sim no **volume do Institucional** combinado com o **peso do contexto dele**.




4. Cruzamento planilha × banco (a prova)

4.1 Modelo de decomposição

O banco tem, desde 12/09, a tabela `rag_retrieval_logs` : **uma linha por turno** do Institucional, que registra o tipo de resposta (camada). Com ela dá para separar os turnos em três grupos:

- **Sem IA** (resposta pronta, encerramento, transbordo): não chamam o gpt-4o.
- **gpt-4o com contexto padrão** (busca vetorial, busca determinística, sem resultado, sem contexto).
- **gpt-4o com programação completa da unidade** (carrega todos os trechos do mês).




Aplicando o peso medido de cada tipo (seção 5), a estimativa diária fica muito próxima do real:

Dia	Turnos gpt-4o padrão	Turnos com programação completa	Tokens estimados (9 mil / 22 mil)	Tokens reais gpt-4o (planilha)	Diferença
19/09	51	6	591 mil	599 mil	+1%
20/09	11	1	121 mil	127 mil	+5%
21/09	182	37	2,45 mi	2,48 mi	+1%
22/09	137	26	1,81 mi	1,85 mi	+2%
23/09 (parcial)	76	13	0,97 mi	1,06 mi	+9%, dia com 186 eventos de currículo

Uma regressão linear nos 12 dias com registro (12 a 23/09) explica **99,8%** da variação diária do gpt-4o. Ela serve só como checagem de consistência: os coeficientes variam conforme a especificação, e os valores de referência são os da medição direta da seção 5.

4.2 Contraprovas independentes


- **Embeddings × vetores:** o número de requisições de embedding por dia bate com as buscas vetoriais do Institucional somadas aos trechos gravados no banco. Em 21/09 foram 203 requisições contra 197 turnos com busca. Em 12/09 foram 523 requisições contra 513 trechos reindexados mais cerca de 10 buscas.
- **Logs das Edge Functions (últimas 24h):** o motor-agente foi chamado **188 vezes** (180 com status 200 e 8 com status 500, média de 4,0 s), contra **187 turnos** registrados. A relação é 1 para 1: **não há chamada duplicada** por reenvio ou timeout do worker.
- **Versões publicadas:** o motor-agente está na **v57**, publicada em 12/09 (04:51 UTC). O `processar-documento` está na v10, de 12/09. O `gerar-resumo-rede` está na v3, de 13/09, e não foi executado desde então. **Nenhuma** Edge Function que consome a OpenAI mudou entre 14 e 23/09.



5. Por que cada resposta do Institucional é cara — anatomia do prompt

Medido no banco e no código, com contagem de tokens feita pelo tokenizador do gpt-4o (o200k_base) sobre amostras reais:

Bloco (entra em todo turno com IA)	Tamanho	Tokens (aprox.)
Prompt de sistema do Institucional (prompts_agentes.prompt_sistema)	7.274 caracteres	≈ 1.700
Regras técnicas (prompt_contexto)	4.017 caracteres	≈ 950
Guardrail de segurança (fixo no código)	5.091 caracteres	1.352 (medido)
Documento "Serviços da Rede" V2, inteiro	15.778 caracteres	≈ 3.800
Histórico (10 mensagens), data/hora, nome, instruções	—	≈ 700
Subtotal fixo por turno		≈ 8.500
+ trechos da busca vetorial (3 a 5)	≈ 400 caracteres cada	≈ 600 → ≈ 9.100
ou + programação completa da unidade	34 a 45 mil caracteres	≈ 10.500 a 13.900 → ≈ 21.000




Custo por turno hoje: cerca de **US\$ 0,023** no turno padrão e cerca de **US\$ 0,053** no turno com programação completa. Com 219 turnos (21/09) isso dá cerca de US\$ 6 por dia.

5.1 Três agravantes estruturais

1. **"Serviços da Rede" vai inteiro em todo turno.** Em 02/09 o documento passou da V1 (8.519 caracteres) para a V2 (15.778), o que somou cerca de **1.800 tokens a toda resposta**, cerca de 25% a mais no turno padrão. Ele foi editado de novo em 17/09 às 15:18 UTC. O documento já está dividido em 22 trechos com vetores no banco, mas o motor-agente não usa esses trechos: carrega o texto completo.
2. **O cache da OpenAI é quase desperdiçado.** A OpenAI dá 50% de desconto nos tokens iniciais repetidos entre chamadas. Hoje o prompt é montado na ordem: sistema, **data e hora** (muda a cada minuto), guardrail, regras, serviços. A data logo no

início quebra o prefixo repetido. Nos dados, o cache fica em **0,8 mil tokens por chamada na média do período**, e a **maior média diária é 1,9 mil** (21/09). Isso é compatível com o prefixo estável terminar no fim do prompt de sistema (estimado em cerca de 1,7 mil tokens). Chamadas no mesmo minuto compartilham a mesma linha de data e podem aproveitar mais, mas isso é a exceção. Nos dias de pouco movimento o cache quase não acontece, porque ele expira após alguns minutos sem chamadas. Se os blocos fixos (cerca de 7,8 mil tokens) viessem antes da data, quase todo o contexto fixo seria cobrado pela metade.

3. **Cada trecho da programação repete um cabeçalho de 2 linhas.** Desde a reindexação de 12/09 existe **um trecho por atividade**, e cada um começa com "PROGRAMAÇÃO MENSAL (9/2026) - Cuca X / Título: Programação Mensal - 9/2026". São **41,0 mil caracteres de cabeçalho repetido** nas 5 unidades, cerca de **21% do texto** que vai no turno de programação completa. Em agosto eram cerca de 45 trechos maiores por unidade, sem essa repetição.



6. Os eventos do período, rastreados

6.1 17/09 — Disparo do Simulado Academia Enem (programação pontual)

Fato (banco)	Valor
Disparo	Evento pontual "SIMULADO ACADEMIA ENEM 2026", enviado pelo número Institucional entre 15:44 e 17:38 UTC
Envios registrados	624 (569 com status de sucesso), mais 9 envios em 4 disparos menores ao longo do dia
Conversas novas no Institucional	456 no dia (média anterior: cerca de 10/dia), 198 delas com marca de disparo recente
Confirmações anotadas (<code>confirmacoes_simulado_ae</code>)	441 no total: 417 por botão (380 "confirmou" e 37 "não vai") e 24 por texto
Respostas do agente no dia	829
Custo do dia	US\$ 7,97 , o maior do mês

Achado — cliques de botão caindo no gpt-4o: o texto "Sim, eu vou!" (o botão de confirmação) aparece **228 vezes** como resposta pronta e **186 vezes** como turno do **gpt-4o** sem contexto (camada `nao_aplicavel`). A causa está no código do motor-agente (`index.ts`, trecho do log "Disparo recente não reconhecido (aguardando_unidade) — ignora resposta canned, segue pro GPT"): **quando a conversa tem a marca de disparo recente, o motor pula a resposta pronta e chama o gpt-4o.** O porteiro da Academia Enem no worker **anota** a confirmação, mas só responde com texto fixo as perguntas de **horário**. O clique de confirmação segue para o motor-agente.

- Custo desses 186 turnos: cerca de 5 mil tokens cada, **cerca de US\$ 2,4**, 31% do dia.
- **Causa confirmada no banco:** todos os 187 turnos "Sim, eu vou!" que foram ao gpt-4o estão em conversas com a marca de disparo recente (`conversas.metadata.ultimo_disparo`).
- O restante do dia são dúvidas reais: 126 buscas vetoriais, 26 turnos de programação completa, 30 sem resultado e 6 determinísticos.

Lembrete: o simulado de **27/09** vai repetir esse padrão se houver novo disparo ou lembrete com botão.

6.2 21 e 22/09 — onda orgânica

Fato	21/09	22/09	23/09 (parcial)
Conversas novas no Institucional	70	54	42
Conversas com marca de disparo	1	1	0
Primeiras mensagens mais comuns	"boa tarde", "oi", "bom dia"		idem
Turnos com gpt-4o (padrão + programação completa)	182 + 37	137 + 26	76 + 13
Conversas com 15 ou mais respostas do agente	6	7	3
Custo	US\$ 5,96	US\$ 4,63	US\$ 3,01

Não houve disparo. São **pessoas novas** puxando conversa, **5 a 7 vezes** a média orgânica anterior, com conversas longas sobre programação. O motivo da procura **não está no banco:** pode ser divulgação do número, redes sociais, abertura de inscrições ou o simulado de 20/09. **Pergunta em aberto para o Junior.**

6.3 12/09 — reindexação da programação de setembro

Os **513 trechos** da programação de setembro foram regravados (um por atividade) e geraram **523 requisições e 76 mil tokens de embedding**, o maior pico de embeddings do mês. **Custo: menos de US\$ 0,002.** O efeito relevante não foi o embedding em si. Foi o formato novo dos trechos, que agora têm cabeçalho repetido (seção 5.1).

6.4 Linha do tempo das mudanças (14/09 → 22/09)

Data (UTC)	Mudança	Afeta o consumo OpenAI?
02/09	"Serviços da Rede" V1 → V2 (8,5 mil → 15,8 mil caracteres)	Sim: +≈1,8 mil tokens em todo turno do Institucional

Data (UTC)	Mudança	Afeta o consumo OpenAI?
08/09	Última edição do prompt do Institucional	Não entra no período
12/09	motor-agente v57, processar-documento v10, reindexação de 513 trechos, criação do registro por turno (rag_retrieval_logs)	Sim, no formato dos trechos (cabeçalho repetido)
13/09	Permissões de programação e programação pontual; gerar-resumo-rede v3	Não (a função não rodou)
15/09	Worker: lista de vagas acima de 4.096 caracteres (Empregabilidade)	Não relevante (gpt-4o-mini)
16/09	Worker: entende resposta de botão (Quick Reply)	Sim, indiretamente: o clique vira texto "Sim, eu vou!" e segue para o motor
17/09	Worker: porteiro anota confirmação e responde horário; FAQ e eventos do simulado indexados; edição de "Serviços da Rede" às 15:18 UTC	Porteiro reduz chamadas (horário); o clique de confirmação continua indo ao gpt-4o; a edição do "Serviços da Rede" soma no máximo cerca de 200 tokens por turno (estimativa: o tamanho anterior não foi registrado; a proporção entre trechos e documento indica uma versão de cerca de 14,9 mil caracteres antes)
21-22/09	Portal: criação manual da programação, rascunho, exclusão por categoria; CI	Não (nenhuma chamada à OpenAI; ver seção 7)

7. Programação inserida manualmente no portal

Fato (banco)	Setembro (importado por planilha)	Outubro (manual, em andamento)
Status	aprovado (publicado)	rascunho nas 5 unidades
Atividades	513	451 (42 em 22/09 e 409 em 23/09)
Texto médio por atividade (título + descrição + dados)	522 caracteres	620 caracteres (+19%)
Texto total	267,7 mil	279,8 mil (+4,5%)

Fato (banco)	Setembro (importado por planilha)	Outubro (manual, em andamento)
Trechos/vetores gerados	513	0 (nada indexado ainda)

Impacto hoje: zero. Rastreamento no código:

- As rotas do portal em `cuca-portal/src/app/api/programacao/*` (rascunho, status, importar, pontual, excluir) **não chamam a OpenAI**.
- A **importação por planilha** chama `/extract-categories` no worker (gpt-4o-mini, centavos).
- A **criação manual não chama** nenhum serviço de IA.
- A indexação (embeddings) só acontece na **publicação** (aprovação), via gatilho que chama `processar-documento`.

Impacto na publicação:

- **Embeddings:** 451 trechos, cerca de 80 mil tokens, **menos de US\$ 0,002**. Irrelevante.
- **Peso do turno "programação completa":** a quantidade de atividades é menor, mas o texto por atividade é mais longo. O resultado é cerca de **+5% de tokens** nesse tipo de turno, mais o cabeçalho repetido (451 trechos × cerca de 80 caracteres, cerca de 36 mil caracteres).
- **O fator dominante continua sendo o volume de conversas.** A publicação costuma vir acompanhada de **divulgação** (disparo), que traz a onda de conversas.

8. Base vetorial — saúde

Item	Situação
Trechos sem vetor	0
Trechos ativos (usados na busca)	641
Trechos de documentos inativos ainda armazenados	854 (não custam OpenAI; só ocupam espaço)
Eventos pontuais ativos duplicados	"Corrida da Juventude" ×4 (evento de julho, passado), "Conexão Futuro CUCA Barra" ×3 (de março e abril, passado ; um deles sem trechos)
Simulado Academia Enem	2 documentos de evento ativos + 1 FAQ de horários (17/09)
Vagas (<code>job_posting</code>) ativas	49 documentos, contra cerca de 30 vagas abertas: documentos de vagas encerradas continuam na busca
Resumo da rede	ativo desde 13/07 (julho), desatualizado

Eventos passados e vagas encerradas ainda ativos **não aumentam o custo** de forma relevante, porque a busca vetorial traz no máximo 3 a 5 trechos. Eles aumentam, porém, o **risco de resposta errada**: o agente pode divulgar evento ou vaga que já acabou, o que gera mais perguntas e mais turnos.

9. Telemetria — o ponto cego

- A tabela `ai_usage_logs` tem **0 linhas**. A tela **Developer** → **Consumo** do portal lê essa tabela e afirma que "o registro automático acontece a cada chamada ao motor-agente". **Isso não está acontecendo**.
 - A tabela `metricas_openai` tem **4 linhas** antigas.
 - A OpenAI devolve em cada resposta o total de tokens usados (`usage`), mas **nenhum** ponto do código grava esse dado.
 - **Consequência:** este diagnóstico precisou reconstruir o consumo cruzando a planilha com tabelas indiretas. A separação exata entre currículos e banco de talentos só pode ser dada como **teto estimado** (cerca de 5–10% do gpt-4o).
-

10. Conclusões

1. **Causa principal:** o volume de conversas no **Institucional** (gpt-4o) triplicou ou quadruplicou em três ondas: disparo do simulado em 17/09 e ondas orgânicas em 21 e 22/09. Cada resposta com IA custa de US\$ 0,02 a US\$ 0,05 por causa do contexto fixo pesado.
 2. **Não houve regressão de código entre 14 e 22/09** que aumentasse o custo por chamada. O aumento estrutural de peso por chamada veio da **V2 de "Serviços da Rede" (02/09)**.
 3. **Desperdício evitável confirmado:** 186 cliques de botão respondidos pelo gpt-4o; cache da OpenAI aproveitando 10–25% do que poderia; "Serviços da Rede" inteiro em todo turno; cabeçalho repetido nos trechos da programação.
 4. **Academia Enem:** o agente próprio da Academia Enem quase não consome. O custo da Academia Enem veio do **disparo feito pelo número Institucional**, que jogou cerca de 450 conversas no motor-agente.
 5. **Programação manual:** sem impacto até a publicação; depois, impacto pequeno (+5% no turno de programação completa). O risco real é a **divulgação** que acompanha a publicação.
 6. **Empregabilidade, banco de talentos, embeddings, imagens:** não explicam o aumento.
 7. **Não existe telemetria de consumo** no sistema, e a tela que diz existir está vazia.
-

Apêndice A — Método e ressalvas

- **Fuso:** todos os dias estão em **UTC**, para casar com as planilhas da OpenAI. Em Fortaleza (UTC–3), parte da noite cai no dia seguinte da tabela.
 - **23/09 é parcial:** planilha exportada à tarde, banco consultado às 21:31 UTC.
 - **Tokens por bloco:** medidos com `tiktoken / o200k_base` sobre amostras reais (programação: 3,24 caracteres por token; texto corrido: cerca de 4,3). O guardrail foi medido inteiro (1.352 tokens).
 - **Currículos e banco de talentos:** não há contador de chamadas. O valor é o **resíduo** do modelo (cerca de 0,8–1 mil tokens por evento de leitura) e deve ser lido como teto.
 - `rag_retrieval_logs` só existe a partir de 12/09. Antes disso, a leitura usa mensagens e conversas.
 - Todas as consultas ao banco foram **somente leitura**.
-

Apêndice B — Consultas principais (reproduzíveis)

```

-- mensagens por dia (UTC) e canal
select (m.created_at at time zone 'UTC')::date d, c.agente_tipo,
       count(*) filter (where m.remetente='agente') resp, count(*) filter (where m.remetente='lead') lead
from mensagens m join conversas c on c.id=m.conversa_id
where m.created_at >= '2026-09-01' group by 1,2 order by 1,2;

-- turnos do Institucional por camada (1 linha por turno)
select (created_at at time zone 'UTC')::date d, camada, count(*)
from rag_retrieval_logs where created_at >= '2026-09-01' group by 1,2 order by 1,2;

-- tamanho do contexto: documentos ativos e seus trechos
select d.tipo, d.unidade_cuca, length(d.conteudo) len_doc, count(c.id) chunks, sum(length(c.conteudo)) len_chunks
from documentos_rag d left join chunks_documentos c on c.documento_id=d.id
where d.ativo group by d.id order by d.tipo;

-- cliques de botão que foram ao GPT
select camada, lower(left(mensagem_lead,30)) msg, count(*)
from rag_retrieval_logs where mensagem_lead ilike 'sim, eu vou%' group by 1,2;

-- disparos do período
select disparo_id, min(created_at), max(created_at), count(*) from logs_disparo
where created_at >= '2026-09-01' group by 1;

-- programação: setembro x outubro
select c.mes, c.status, count(a.*), round(avg(length(coalesce(a.titulo,''))+length(coalesce(a.descricao,'')))+length
from campanhas_mensais c join atividades_mensais a on a.campanha_id=c.id
where c.ano=2026 and c.mes in (9,10) group by 1,2;

```

Séries diárias consolidadas: [dados/serie_diaria_consolidada.csv](#) .